

Grandes Modelos de Linguagem

Alunos: João Gabriel de Moraes Bezerra e Daniel Henrique Peres Servejeira

Laboratório de Simulações Numéricas e Inteligência Artificial

4 de junho de 2026



Modelos de linguagem

Lembre-se do modelo de linguagem simples n-grama:

- Atribui probabilidades a sequências de palavras;
- Gera texto amostrando possíveis próximas palavras;
- É treinado em contagens de frequência computadas a partir de corpora textuais massivos.

Grandes modelos de linguagem compartilham semelhanças, mas diferem fundamentalmente:

- Atribuem probabilidades a sequências de palavras;
- Geram texto amostrando possíveis próximas palavras;
- São treinados utilizando redes neurais profundas para aprender a adivinhar a próxima palavra.

Grandes modelos de linguagem

Mesmo que esses modelos complexos sejam pré-treinados exclusivamente com o objetivo simples de prever a próxima palavra sequencial, eles implicitamente aprendem uma quantidade massiva de estrutura linguística útil, conhecimento factual e capacidades de raciocínio devido à escala astronômica dos textos que processam durante o treinamento.

Três arquiteturas para grandes modelos de linguagem

Decodificadores

- Série GPT
- Claude
- Llama
- Mixtral

Codificadores

- Família BERT
- HUBERT

Codificadores-decodificadores

- Flan-T5
- Whisper

Espaço para Imagem (Arquiteturas)

Insira o diagrama das arquiteturas aqui.

Codificadores

Muitas variedades existem no ecossistema:

- Variante mais popular: Modelos de Linguagem Mascarada (MLMs), como a família BERT.
- Treinados prevendo palavras que foram artificialmente mascaradas do contexto ao redor em ambos os lados, esquerdo e direito.
- Por serem bidirecionais, eles geralmente passam por um ajuste fino (treinados em dados supervisionados) exclusivamente para tarefas de classificação e extração em vez de geração.

Espaço para Imagem
Insira o diagrama de Codificadores.

Codificadores-Decodificadores

Treinados fundamentalmente para mapear de uma sequência completa para outra.

Muito populares para tarefas que requerem compreensão total do contexto:

- Tradução automática (mapear uma frase inteiramente de um idioma para outro)
- Reconhecimento de fala (mapear acústica de áudio bruto em palavras escritas)

Espaço para Imagem

Insira o diagrama Encoder-Decoder.

Grandes Modelos de Linguagem

Grandes Modelos de Linguagem

Quais tarefas eles podem realizar?

A grande ideia

Um avanço monumental no processamento de linguagem natural é a constatação de que muitas tarefas cognitivas complexas podem ser reformuladas matematicamente como tarefas simples de prever palavras!

Nesta aula: modelos apenas decodificadores

Modelos apenas decodificadores são comumente chamados de:

- LLMs Causais
- LLMs Autorregressivos
- LLMs da Esquerda para a Direita

Esses modelos funcionam estritamente prevendo palavras sequencialmente da esquerda para a direita, sendo totalmente incapazes de analisar o contexto futuro.

Geração Condicional

Gerando texto logicamente condicionado ao texto anterior!

Espaço para Imagem (Geração Condicional)
Insira a imagem ilustrativa aqui.

Formulando muitas tarefas como previsão de palavras: Análise de Sentimentos

Análise de sentimentos da frase: "Eu gosto do Jackie Chan"

- 1 Nós fornecemos ao modelo de linguagem autorregressivo esta string de prefixo específica:
O sentimento da frase "Eu gosto do Jackie Chan" é:
- 2 Em seguida, avaliamos a probabilidade matemática da palavra que ele acha que vem a seguir:

$$P(\text{positivo} \mid \text{prefixo}) \quad \text{versus} \quad P(\text{negativo} \mid \text{prefixo})$$

O modelo avalia as probabilidades de pares semânticos como gostar/odiar, amar/não gostar e adorar/detestar para executar a classificação.

Formulando muitas tarefas como geração condicional: QA

Perguntas e Respostas (QA): "Quem escreveu A Origem das Espécies"

- 1 Damos ao modelo de linguagem esta string estrutural rigorosa:
P: Quem escreveu o livro "A Origem das Espécies"? R:
- 2 E avaliamos qual palavra a distribuição de probabilidade indica que virá a seguir.
- 3 Anexamos o resultado e iteramos o processo:
P: Quem escreveu o livro "A Origem das Espécies"? R: Charles

Resumo via Geração Condicional

Exemplo de Artigo Original:

A única coisa mais louca do que um cara na nevada Massachusetts empacotando aquela neve branquinha e oferecendo-a para venda online? As pessoas estão realmente comprando. Por US\$ 89, o auto-intitulado empreendedor Kyle Waring enviará cerca de 3 quilos de neve da área de Boston em uma caixa de isopor isolada - o suficiente para 10 a 15 bolas de neve, diz ele. Mas não se você mora na Nova Inglaterra ou nos estados vizinhos.

Resumo Gerado (solicitado por "tl;dr"):

Kyle Waring enviará a você cerca de 3 quilos de neve da área de Boston em uma caixa isolada, o suficiente para 10 a 15 bolas de neve, diz ele. Mas não se você mora na Nova Inglaterra ou nos estados vizinhos. Ele brincou sobre enviar o material para amigos e familiares em estados mais quentes, e assim nasceu uma ideia.

Amostragem para Geração de LLMs

Amostragem para Geração de LLMs

Decodificação e Amostragem

- A tarefa computacional de escolher uma palavra específica para gerar com base nas probabilidades de saída do modelo é chamada de **decodificação**.
- O método mais comum para decodificação em LLMs é a **amostragem**.
- Amostrar a partir da distribuição de palavras de um modelo envolve escolher palavras aleatórias de acordo com a probabilidade matemática precisa atribuída pela rede.
- Após cada token ser gerado, amostramos palavras subsequentes de acordo com sua probabilidade estritamente condicionada a todas as nossas escolhas anteriores.
- Um modelo de linguagem Transformer produzirá continuamente essa distribuição de probabilidade sobre o vocabulário.

Amostragem aleatória

Intuição algorítmica para a amostragem aleatória pura:

```
i = 1
w_1 ← p(w)
while w_i ≠ EOS:
    i = i + 1
    w_i ← p(w | w_1, ..., w_{i-1})
```

- i e w_i : Rastreiam o índice posicional e a palavra escolhida.
- $\leftarrow p$: Indica a extração probabilística da palavra a partir da distribuição.
- **EOS**: O sinal crítico de parada (Fim da Sequência).
- $P(w | \dots)$: A escolha da próxima palavra depende de todo o contexto histórico.

A amostragem aleatória não funciona muito bem...

- Embora a amostragem aleatória pura geralmente gere palavras coerentes e de alta probabilidade, existem milhares de palavras estranhas e de baixa probabilidade residindo na cauda da distribuição.
- Cada uma dessas palavras individuais possui uma probabilidade mínima, mas quando somadas matematicamente, elas constituem uma parte grande e perigosa da massa de probabilidade total.
- Portanto, sob amostragem aleatória pura, elas são escolhidas com frequência suficiente para gerar frases completamente estranhas e sem sentido.

Fatores na amostragem de palavras: Qualidade vs. Diversidade

Enfatizar palavras com probabilidade média introduz diversidade:

- **Prós:** Resulta em saídas textuais muito mais criativas e diversas.
- **Contras:** Reduz drasticamente a qualidade, resultando em declarações menos factuais e altamente inconsistentes.

Enfatizar palavras exclusivamente com alta probabilidade prioriza a qualidade:

- **Prós:** Garante que as saídas sejam altamente precisas, logicamente coerentes e factuais.
- **Contras:** Erradica a diversidade, produzindo textos entediantes, altamente repetitivos e robóticos.

Algoritmo de Amostragem Top-k

Para truncar a perigosa cauda de probabilidade, utilizamos o Top-k:

- 1 Escolha um valor inteiro estático " k " representando o número de palavras.
- 2 Para cada palavra em todo o vocabulário V , use o modelo de linguagem para calcular a probabilidade dessa palavra dado o prefixo contextual $p(w_t | w_{<t})$.
- 3 Ordene as palavras sequencialmente por probabilidade, mantendo apenas as " k " palavras mais prováveis e descartando o resto.
- 4 Renormalize as pontuações das k palavras restantes para que somem 1, criando uma distribuição de probabilidade válida.
- 5 Selecione aleatoriamente uma palavra das k palavras restantes, estritamente de acordo com sua probabilidade renormalizada.

Amostragem Top-p (= amostragem de núcleo)

Problema Fundamental com o top-k: O parâmetro k é fixo, o que significa que pode abranger quantidades muito diferentes da massa de probabilidade total em situações contextuais diferentes (por exemplo, distribuições planas vs. acentuadas).

A Ideia do Núcleo: Em vez de uma contagem fixa, mantenha os p por cento superiores da massa de probabilidade.

Dada uma distribuição $P(w_t \mid w_{<t})$, o vocabulário top-p $V(p)$ é definido matematicamente como o menor conjunto de palavras tal que:

$$\sum_{w \in V(p)} P(w \mid w_{<t}) \geq p$$

(Holtzman et al., 2020)

Amostragem por temperatura (1/3)

Em vez de truncar o vocabulário, podemos remodelar matematicamente toda a distribuição. Esse conceito extrai intuição da termodinâmica:

- Um sistema físico existente a uma temperatura alta é altamente flexível, energético e pode explorar muitos estados variantes possíveis.
- Um sistema a uma temperatura mais baixa possui energia mais baixa e tem maior probabilidade matemática de explorar apenas um pequeno subconjunto de estados (melhores) estáveis.

Em configurações de amostragem de baixa temperatura ($\tau \leq 1$), forçamos suavemente o algoritmo a:

- Aumentar drasticamente a probabilidade das palavras mais prováveis.
- Diminuir simultaneamente a probabilidade das palavras raras de cauda longa.

Amostragem por temperatura (2/3)

- **t = 0.1 a 0.3 (Variância Muito Baixa):** Excepcional para executar código de programação, equações matemáticas, traduções estritas ou responder a consultas factuais onde se deseja precisão absoluta e nenhum desvio criativo. O modelo quase sempre escolherá de forma gananciosa a palavra mais lógica.
- **t = 0.7 a 1.0 (Variância Normal/Alta):** Ideal para escrever poesia, sessões de brainstorming ou gerar histórias narrativas, pois a distribuição matemática permite que o modelo arrisque selecionar palavras menos óbvias, gerando uma saída textual muito mais diversa e "criativa".

Amostragem por temperatura (3/3)

Matematicamente, dividimos o logit bruto u por um parâmetro de temperatura τ antes de passá-lo pela camada final de ativação softmax.

Em vez do cálculo padrão:

$$y = \text{softmax}(u)$$

Calculamos a variante escalonada:

$$y = \text{softmax}\left(\frac{u}{\tau}\right)$$

Por que esse ajuste estrutural funciona?

- Quando τ é exatamente 1, a distribuição matemática não muda.
- Quanto menor o τ , maiores serão as pontuações diferenciais passadas para o softmax. O softmax empurra inerentemente valores altos para 1 e valores baixos para 0.
- Conforme $\tau \rightarrow 0$, a probabilidade da palavra absolutamente mais provável se

Pré-treinamento de Grandes Modelos de Linguagem

Pré-treinamento de Grandes Modelos de Linguagem

Algoritmos e Arquiteturas

Paradigma de Pré-treinamento

A ideia monumental que impulsiona as incríveis métricas de desempenho dos modelos de linguagem modernos:

- Primeiro, pré-treinar um modelo Transformer massivo em quantidades astronomicamente grandes de texto bruto usando clusters de computação massivos.
- Em seguida, aplicar esse conhecimento generalizado a novas tarefas altamente específicas.

Algoritmo de treinamento autossupervisionado

Nós fundamentalmente apenas os treinamos para prever a próxima palavra!

Pegue um corpus massivo de texto. A cada passo de tempo computacional t ...

- 1 Peça ao modelo neural para prever matematicamente a próxima palavra na sequência.
- 2 Treine o modelo utilizando a retropropagação (backpropagation) do erro e a descida do gradiente para minimizar o erro matemático nesta previsão.

Esse paradigma é classificado como aprendizado **"Autossupervisionado"** porque não requer anotadores humanos; ele simplesmente utiliza a próxima palavra natural no texto como o rótulo definitivo de verdade de base (ground-truth)!

Intuição do treinamento do modelo de linguagem: Perda

- **Utilidade da Função de Perda:** A métrica padrão é a perda de entropia cruzada.
- Inerentemente, queremos que o modelo neural atribua uma alta probabilidade à palavra verdadeira e empírica w .
- Consequentemente, queremos que a perda calculada seja excepcionalmente alta se o modelo atribuir uma probabilidade muito baixa a w .
- **Definição da Perda CE:** O logaritmo negativo da probabilidade que o modelo atribui exclusivamente à próxima palavra verdadeira w .
- Se o modelo atribui uma probabilidade muito baixa a w , o otimizador move forçosamente os bilhões de pesos do modelo na direção multidimensional que garante uma atribuição de probabilidade maior a w no futuro.

Perda de entropia cruzada para modelagem de linguagem

A perda CE define a divergência entre a distribuição de probabilidade correta e empírica e a distribuição prevista pelo modelo:

$$L_{CE} = - \sum_{w \in V} y_t[w] \log \hat{y}_t[w]$$

A distribuição verdadeira (ground-truth) correta y_t sabe a próxima palavra definitivamente, então ela funciona como um vetor one-hot: é exatamente 1 para a próxima palavra real e 0 para todos os outros tokens.

Portanto, nesta soma, todos os termos são multiplicados por zero e desaparecem, exceto um: a probabilidade logarítmica que o modelo atribui à próxima palavra correta. Assim:

$$L_{CE}(\hat{y}_t, y_t) = -\log \hat{y}_t[w_{t+1}]$$

Técnica de Teacher Forcing

- Em cada posição de token t , o modelo processa os tokens históricos corretos $w_{1:t}$.
- Ele calcula a perda (o logaritmo negativo da probabilidade) para sua previsão do próximo token w_{t+1} .
- Criticamente, na posição do token subsequente $t + 1$, ignoramos estritamente qualquer token errôneo que o modelo possa ter previsto para w_{t+1} .
- Em vez disso, pegamos a palavra verdadeira correta w_{t+1} do conjunto de dados, adicionamos de forma segura ao contexto e seguimos em frente. Isso evita o acúmulo de erros durante o treinamento.

Treinando um modelo de linguagem transformer

Espaço para Imagem (Treinamento do Transformer)

Insira o diagrama do fluxo de treinamento aqui.

$$\text{Perda Total do Lote} = \frac{1}{T} \sum_{t=1}^T L_{CE}$$

Os LLMs são treinados principalmente na web

- **Common Crawl:** Instantâneos massivos de toda a web pública produzidos recursivamente pela organização sem fins lucrativos Common Crawl, contendo bilhões de páginas HTML brutas.
- **Colossal Clean Crawled Corpus (C4):** Criado por Raffel et al. (2020), este conjunto de dados contém 156 bilhões de tokens de texto em inglês que foram rigorosamente filtrados por qualidade.
- **O que constitui esses dados?** A maior parte dos tokens de alta qualidade deriva de documentos de patentes, bancos de dados da Wikipedia e sites de notícias internacionais.

The Pile: um corpus de pré-treinamento projetado

Um conjunto de dados de modelagem de linguagem de código aberto de 825 GiB diversificado e meticulosamente balanceado.

Acadêmico	Web & Geral	Livros & Diálogos
PubMed Central	Pile-CC	Bibliotik
ArXiv	OpenWebText2	PG-19
FreeLaw	StackExchange	BookCorpus2
PhilPapers	Wikipedia	Ubuntu IRC / GitHub

O que um modelo aprende no pré-treinamento?

O texto bruto ingerido contém uma enorme quantidade de conhecimento humano. O pré-treinamento com bilhões de textos contendo todo esse conhecimento é o que fundamentalmente dá aos modelos de linguagem sua capacidade de executar tanta lógica.

- Lógica Contextual: "Há caninos por toda parte! Um cachorro na sala da frente e dois cachorros."
- Escalonamento Semântico: "Não era apenas grande, era enorme."
- Recuperação Factual: "A autora de 'Um Teto Todo Seu' é Virginia Woolf."
- Verdades Matemáticas: "A raiz quadrada de 4 é 2."

Ajuste fino como "pré-treinamento contínuo"

- A abordagem mais direta é treinar ainda mais todos os bilhões de parâmetros do modelo nos novos dados específicos.
- Empregamos exatamente o mesmo método (previsão da próxima palavra) e função de perda matemática (perda de entropia cruzada) utilizados para o pré-treinamento original.
- Tratamos a operação como se os novos dados especializados fossem simplesmente anexados no final da sequência massiva de dados de pré-treinamento.
- Portanto, esse processo é frequentemente classificado na literatura como **pré-treinamento contínuo**.

Métrica de Perplexidade

A indústria usa a Perplexidade para medir matematicamente quão bem o LM prevê distribuições de texto não vistas.

A perplexidade de um modelo em um conjunto de teste não visto é definida como o inverso da probabilidade que o modelo atribui ao conjunto de teste, normalizada geometricamente pelo comprimento do conjunto de teste.

Para uma sequência de teste de n tokens $w_{1:n}$, a perplexidade é calculada como:

$$\text{Perplexidade}(w_{1:n}) = P(w_{1:n})^{-\frac{1}{n}}$$

Por que perplexidade em vez de probabilidade bruta?

- A probabilidade bruta depende inteiramente do tamanho do conjunto de teste; a probabilidade se torna assintoticamente menor quanto mais longa for a sequência de texto.
- A perplexidade calcula a probabilidade inversa normalizada pelo número total de palavras (derivada da taxa de entropia cruzada).
- Enquanto a probabilidade opera em uma faixa estreita de $[0, 1]$, a faixa de perplexidade abrange $[1, \infty]$.
- Quanto maior a probabilidade atribuída à sequência de palavras, menor a perplexidade.

Leis de Escala

O desempenho empírico do LLM é estritamente dependente de:

- **Tamanho do modelo:** Número absoluto de parâmetros treináveis.
- **Tamanho do conjunto de dados:** A quantidade volumétrica bruta de dados.
- **Computação:** Quantidade absoluta de computação utilizada.

O desempenho de um grande modelo de linguagem (medido pela perda) escala matematicamente como uma lei de potência:

$$L(N) = (N_c/N)^{\alpha_N} \quad L(D) = (D_c/D)^{\alpha_D} \quad L(C) = (C_c/C)^{\alpha_C}$$

Número de parâmetros não-embedding N

Podemos estimar matematicamente o total de parâmetros via:

$$N \approx 2d_{model}n_{layers}(2d_{attn} + d_{ff})$$
$$\approx 12n_{layers}d_{model}^2$$

Assumindo proporções dimensionais padrão de $d_{attn} = d_{ff}/4 = d_{model}$.

Assim, calculando para a arquitetura do GPT-3, possuindo $n = 96$ camadas e uma dimensionalidade massiva de $d = 12288$, determinamos:

$$12 \times 96 \times 12288^2 \approx 175 \text{ bilhões de parâmetros.}$$

O Gargalo do Cache KV

Durante a fase de pré-treinamento, calculamos a atenção matemática com eficiência em lotes paralelos massivos. Porém, isso falha na inferência, pois geramos tokens sequencialmente.

- Para cada novo token x , multiplicamos pelas matrizes de peso W_Q, W_K, W_V .
- O cálculo exige vetores chave e valor para todos os tokens anteriores $x_{<i}$, gerando um custo computacional $O(N^2)$.
- **A Solução de Engenharia:** Armazene os vetores na memória VRAM da GPU no cache KV, para uso com velocidade de inferência $O(N)$.

Espaço para Imagem do Cache KV

Teoria LORA (Adaptação de Baixo Posto)

Considere uma matriz de pesos base W ($N \times d$) que teoricamente precisa ser atualizada durante o ajuste fino. No algoritmo LORA, congelamos W e atualizamos uma decomposição de baixo posto de W :

- Matriz A com formato $N \times r$
- Matriz B com formato $r \times d$
- Onde r (posto) é muito pequeno (ex: 1, 2 ou 8)

Substituímos computacionalmente $W + \Delta W$ por $W + BA$.

Passagem direta (Forward pass):

$$h = xW + xAB$$

Danos Sociais dos Grandes Modelos de Linguagem

- **Alucinação:** Chatbots rotineiramente 'alucinam' políticas corporativas falsas ou fatos inexistentes.
- **Litígio de Direitos Autorais:** Ações judiciais por infração massiva no uso de obras protegidas durante o treinamento sem permissão.
- **Violações de Privacidade:** Vazamento accidental de e-mails e números de telefone privados extraídos dos dados de treinamento.
- **Toxicidade e Exploração:** O processo de limpeza dos dados muitas vezes exige que humanos avaliem conteúdos tóxicos.
- **Desinformação Política:** Geração de falsidades altamente persuasivas que podem afetar cenários globais e eleições.

Referências Bibliográficas I

-  Anthropic. 2025. Release notes: System prompts.
<https://docs.anthropic.com/en/release-notes/system-prompts>.
-  Bellegarda, J. R. 1997. A latent semantic analysis framework for large-span language modeling. EUROSPEECH.
-  Bengio, Y., R. Ducharme, and P. Vincent. 2000. A neural probabilistic language model. NeurIPS.
-  Bengio, Y., R. Ducharme, P. Vincent, and C. Jauvin. 2003. A neural probabilistic language model. JMLR, 3:1137–1155.
-  Bengio, Y., H. Schwenk, J.-S. Senécal, F. Morin, and J.-L. Gauvain. 2006. Neural probabilistic language models. In Innovations in Machine Learning, 137–186. Springer.
-  Bickmore, T. W., et al. 2018. Patient and consumer safety risks when using conversational assistants for medical information. Journal of Medical Internet Research, 20(9):e11510.
-  Blodgett, S. L., S. Barocas, H. Daumé III, and H. Wallach. 2020. Language (technology) is power: A critical survey of “bias” in NLP. ACL.
-  Bommasani, R., et al. 2021. On the opportunities and risks of foundation models. ArXiv.
-  Brown, T., et al. 2020. Language models are few-shot learners. NeurIPS, 33.
-  Carlini, N., et al. 2021. Extracting training data from large language models. USENIX Security 21.

Referências Bibliográficas II

-  Cheng, M., E. Durmus, and D. Jurafsky. 2023. Marked personas: Using natural language prompts to measure stereotypes in language models. ACL.
-  Cheng, M., et al. 2025. Sycophantic ai decreases prosocial intentions and promotes dependence. ArXiv preprint.
-  Coccaro, N. and D. Jurafsky. 1998. Towards better integration of semantic predictors in statistical language modeling. ICSLP.
-  Dai, A. M. and Q. V. Le. 2015. Semi-supervised sequence learning. NeurIPS.
-  Deerwester, S. C., et al. 1988. Computer information retrieval using latent semantic structure: US Patent 4,839,853.
-  Devlin, J., M.-W. Chang, K. Lee, and K. Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. NAACL HLT.
-  Dinan, E., et al. 2020. Queens are powerful too: Mitigating gender bias in dialogue generation. EMNLP.
-  Dinan, E., et al. 2021. Anticipating safety issues in e2e conversational ai: Framework and tooling. ArXiv.
-  Dodge, J., et al. 2019. Show your work: Improved reporting of experimental results. EMNLP.

Referências Bibliográficas III

-  Dodge, J., et al. 2021. Documenting large webtext corpora: A case study on the colossal clean crawled corpus. EMNLP.
-  Ethayarajh, K. and D. Jurafsky. 2020. Utility is in the eye of the user: A critique of NLP leaderboards. EMNLP.
-  Friedman, B., D. G. Hendry, and A. Borning. 2017. A survey of value sensitive design methods. Foundations and Trends in Human-Computer Interaction.
-  Friedman, B. and D. G. Hendry. 2019. Value Sensitive Design: Shaping Technology with Moral Imagination. MIT Press.
-  Gao, L., et al. 2020. The Pile: An 800GB dataset of diverse text for language modeling. ArXiv.
-  Gehman, S., S. Gururangan, M. Sap, Y. Choi, and N. A. Smith. 2020. RealToxicityPrompts: Evaluating neural toxic degeneration in language models. Findings of EMNLP.
-  Gururangan, S., et al. 2020. Don't stop pretraining: Adapt language models to domains and tasks. ACL.
-  Hashimoto, T., M. Srivastava, H. Namkoong, and P. Liang. 2018. Fairness without demographics in repeated loss minimization. ICML.
-  Heafield, K. 2011. KenLM: Faster and smaller language model queries. Workshop on Statistical Machine Translation.

Referências Bibliográficas IV

-  Henderson, P., et al. 2017. Ethical challenges in data-driven dialogue systems. AAAI/ACM AI Ethics and Society Conference.
-  Henderson, P., et al. 2020. Towards the systematic reporting of the energy and carbon footprints of machine learning. JMLR.
-  Henderson, P., et al. 2023. Foundation models and fair use. JMLR, 24(400):1–79.
-  Hofmann, V., P. R. Kalluri, D. Jurafsky, and S. King. 2024. Ai generates covertly racist decisions about people based on their dialect. Nature, 633(8028):147–154.
-  Ischen, C., et al. 2019. Privacy concerns in chatbot interactions. International Workshop on Chatbot Research and Design.
-  Jelinek, F., R. L. Mercer, and L. R. Bahl. 1975. Design of a linguistic statistical decoder for the recognition of continuous speech. IEEE Transactions on Information Theory.
-  Khattab, O., et al. 2024. DSPy: Compiling declarative language model calls into self-improving pipelines. ICLR.
-  Kiela, D., et al. 2021. Dynabench: Rethinking benchmarking in NLP. NAACL HLT.
-  Landauer, T. K., D. Laham, B. Rehder, and M. E. Schreiner. 1997. How well can passage meaning be derived without using word order? COGSCI.

Referências Bibliográficas V

-  Liang, P., et al. 2023. Holistic evaluation of language models. Transactions on Machine Learning Research.
-  Liu, H., et al. 2020. Does gender matter? Towards fairness in dialogue systems. COLING.
-  Llama Team. 2024. The llama 3 herd of models.
-  Longpre, S., et al. 2024a. Consent in crisis: The rapid decline of the ai data commons. ArXiv preprint.
-  Longpre, S., et al. 2024b. A pretrainer's guide to training data: Measuring the effects of data age, domain coverage, quality, & toxicity. NAACL HLT.
-  McGuffie, K. and A. Newhouse. 2020. The radicalization risks of GPT-3 and advanced neural language models. ArXiv.
-  Mikolov, T., et al. 2010. Recurrent neural network based language model. INTERSPEECH.
-  Mikolov, T., et al. 2011. Extensions of recurrent neural network language model. ICASSP.
-  Mikolov, T., K. Chen, G. S. Corrado, and J. Dean. 2013a. Efficient estimation of word representations in vector space. ICLR.
-  Mikolov, T., I. Sutskever, K. Chen, G. S. Corrado, and J. Dean. 2013b. Distributed representations of words and phrases and their compositionality. NeurIPS.

Referências Bibliográficas VI

-  Miller, G. A. and J. A. Selfridge. 1950. Verbal context and the recall of meaningful material. *American Journal of Psychology*, 63:176–185.
-  Min, S., et al. 2022. Rethinking the role of demonstrations: What makes in-context learning work? EMNLP.
-  Nadeem, M., A. Bethke, and S. Reddy. 2021. StereoSet: Measuring stereotypical bias in pretrained language models. *ACL*.
-  Neff, G. and P. Nagy. 2016. Talking to bots: Symbiotic agency and the case of Tay. *International Journal of Communication*.
-  Parrish, A., et al. 2022. BBQ: A hand-built bias benchmark for question answering. *Findings of ACL 2022*.
-  Peters, M., et al. 2018. Deep contextualized word representations. *NAACL HLT*.
-  Radford, A., et al. 2019. Language models are unsupervised multitask learners. *OpenAI tech report*.
-  Raffel, C., et al. 2020. Exploring the limits of transfer learning with a unified text-to-text transformer. *JMLR*, 21(140):1–67.
-  Rawls, J. 2001. *Justice as fairness: A restatement*. Harvard University Press.
-  Reeves, B. and C. Nass. 1996. *The Media Equation: How People Treat Computers, Television, and New Media Like Real People and Places*. Cambridge University Press.

Referências Bibliográficas VII

-  Rosenfeld, R. 1992. Adaptive Statistical Language Modeling: A Maximum Entropy Approach. Ph.D. thesis, Carnegie Mellon University.
-  Rosenfeld, R. 1996. A maximum entropy approach to adaptive statistical language modeling. *Computer Speech and Language*, 10:187–228.
-  Sagawa, S., P. W. Koh, T. B. Hashimoto, and P. Liang. 2020. Distributionally robust neural networks for group shifts: On the importance of regularization for worst-case generalization. *ICLR*.
-  Shannon, C. E. 1948. A mathematical theory of communication. *Bell System Technical Journal*, 27(3):379–423.
-  Sheng, E., K.-W. Chang, P. Natarajan, and N. Peng. 2019. The woman worked as a babysitter: On biases in language generation. *EMNLP*.
-  Soldaini, L., et al. 2024. Dolma: An open corpus of three trillion tokens for language model pretraining research. *ArXiv*.
-  Stolcke, A. 2002. SRILM – an extensible language modeling toolkit. *ICSLP*.
-  Strubell, E., A. Ganesh, and A. McCallum. 2019. Energy and policy considerations for deep learning in NLP. *ACL*.
-  Vaswani, A., et al. 2017. Attention is all you need. *NeurIPS*.

Referências Bibliográficas VIII

-  Webson, A. and E. Pavlick. 2022. Do prompt-based models really understand the meaning of their prompts? NAACL HLT.
-  Weizenbaum, J. 1966. ELIZA – A computer program for the study of natural language communication between man and machine. CACM.
-  Wolf, M. J., K. W. Miller, and F. S. Grodzinsky. 2017. Why we should have seen that coming: Comments on Microsoft's Tay “experiment,” and wider implications. The ORBIT Journal.
-  Xu, J., et al. 2020. Recipes for safety in open-domain chatbots. ArXiv.
-  Xu, A., et al. 2021. Detoxifying language models risks marginalizing minority voices. NAACL HLT.
-  Zao-Sanders, M. 2025. How People Are Really Using Gen AI in 2025 — hbr.org.
<https://hbr.org/2025/04/how-people-are-really-using-gen-ai-in-2025>.
-  Zhang, A. K., et al. 2025. Language model developers should report train-test overlap. ICML.

