

# Grandes Modelos de Linguagem

**Alunos:** João Gabriel de Morais Bezerra e Daniel Henrique Peres Servejeira

Laboratório de Simulações Numéricas e Inteligência Artificial

12 de julho de 2026



UNIVERSIDADE ESTADUAL PAULISTA  
"JÚLIO DE MESQUITA FILHO"

# Modelos de linguagem

## Lembre-se do modelo de linguagem simples n-grama:

- Atribui probabilidades a sequências de palavras;
- Gera texto amostrando possíveis próximas palavras;
- É treinado em contagens de frequência computadas a partir de corpora textuais massivos.

## Grandes modelos de linguagem compartilham semelhanças, mas diferem fundamentalmente:

- Atribuem probabilidades a sequências de palavras;
- Geram texto amostrando possíveis próximas palavras;
- São treinados utilizando redes neurais profundas para aprender a adivinhar a próxima palavra.


# Grandes modelos de linguagem

Mesmo que esses modelos complexos sejam pré-treinados exclusivamente com o objetivo simples de prever a próxima palavra sequencial, eles implicitamente aprendem uma quantidade massiva de estrutura linguística útil, conhecimento factual e capacidades de raciocínio devido à escala astronômica dos textos que processam durante o treinamento.

# Três arquiteturas para grandes modelos de linguagem


## Decodificadores

- GPT Series
- Claude
- Llama
- Mixtral




## Codificadores

- BERT family
- HUBERT



## Codificadores- Decodificadores


- Flan-T5
- Whisper



# Codificadores

## Muitas variedades existem no ecossistema:

- Variante mais popular: Modelos de Linguagem Mascarada (MLMs), como a família BERT.
- Treinados prevendo palavras que foram artificialmente mascaradas do contexto ao redor em ambos os lados, esquerdo e direito.
- Por serem bidirecionais, eles geralmente passam por um ajuste fino (treinados em dados supervisionados) exclusivamente para tarefas de classificação e extração em vez de geração.




# Codificadores-Decodificadores

**Treinados fundamentalmente para mapear de uma sequência completa para outra.**

**Muito populares para tarefas que requerem compreensão total do contexto:**

- Tradução automática (mapear uma frase inteiramente de um idioma para outro)
- Reconhecimento de fala (mapear acústica de áudio bruto em palavras escritas)



# Grandes Modelos de Linguagem

## Grandes Modelos de Linguagem

Quais tarefas eles podem realizar?

# A grande ideia

Um avanço monumental no processamento de linguagem natural é a constatação de que muitas tarefas cognitivas complexas podem ser reformuladas matematicamente como tarefas simples de prever palavras!

# Nesta aula: modelos apenas decodificadores

## Modelos apenas decodificadores são comumente chamados de:

- LLMs Causais
- LLMs Autorregressivos
- LLMs da Esquerda para a Direita

Esses modelos funcionam estritamente prevendo palavras sequencialmente da esquerda para a direita, sendo totalmente incapazes de analisar o contexto futuro.

## Gerando texto logicamente condicionado ao texto anterior!




Figura: Esquema de previsão de texto.

# Formulando muitas tarefas como previsão de palavras: Análise de Sentimentos

## Análise de sentimentos da frase: "Eu gosto do Jackie Chan"

- 1 Nós fornecemos ao modelo de linguagem autorregressivo esta string de prefixo específica:  
*O sentimento da frase "Eu gosto do Jackie Chan" é:*
- 2 Em seguida, avaliamos a probabilidade matemática da palavra que ele acha que vem a seguir:

$$P(\text{positivo} \mid \text{prefixo}) \quad \text{versus} \quad P(\text{negativo} \mid \text{prefixo})$$

O modelo avalia as probabilidades de pares semânticos como gostar/odiar, amar/não gostar e adorar/detestar para executar a classificação.

# Formulando muitas tarefas como geração condicional: QA

## Perguntas e Respostas (QA): "Quem escreveu A Origem das Espécies"

- 1 Damos ao modelo de linguagem esta string estrutural rigorosa:  
P: Quem escreveu o livro "A Origem das Espécies"? R:
- 2 E avaliamos qual palavra a distribuição de probabilidade indica que virá a seguir.
- 3 Anexamos o resultado e iteramos o processo:  
P: Quem escreveu o livro "A Origem das Espécies"? R: Charles

# Resumo via Geração Condicional

## Exemplo de Artigo Original:

A única coisa mais louca do que um cara na nevada Massachusetts empacotando aquela neve branquinha e oferecendo-a para venda online? As pessoas estão realmente comprando. Por US\$ 89, o auto-intitulado empreendedor Kyle Waring enviará cerca de 3 quilos de neve da área de Boston em uma caixa de isopor isolada - o suficiente para 10 a 15 bolas de neve, diz ele. Mas não se você mora na Nova Inglaterra ou nos estados vizinhos.

## Resumo Gerado (solicitado por "tl;dr"):

Kyle Waring enviará a você cerca de 3 quilos de neve da área de Boston em uma caixa isolada, o suficiente para 10 a 15 bolas de neve, diz ele. Mas não se você mora na Nova Inglaterra ou nos estados vizinhos. Ele brincou sobre enviar o material para amigos e familiares em estados mais quentes, e assim nasceu uma ideia.

# Sumarização de texto

Executando compressão usando o delimitador "Too long; didn't read".




Figura: Esquema de resumo de texto.

# Amostragem para Geração de LLMs

## Amostragem para Geração de LLMs

# Decodificação e Amostragem

- A tarefa computacional de escolher uma palavra específica para gerar com base nas probabilidades de saída do modelo é chamada de **decodificação**.
- O método mais comum para decodificação em LLMs é a **amostragem**.
- Amostrar a partir da distribuição de palavras de um modelo envolve escolher palavras aleatórias de acordo com a probabilidade matemática precisa atribuída pela rede.
- Após cada token ser gerado, amostramos palavras subsequentes de acordo com sua probabilidade estritamente condicionada a todas as nossas escolhas anteriores.
- Um modelo de linguagem Transformer produzirá continuamente essa distribuição de probabilidade sobre o vocabulário.

# Amostragem aleatória

Intuição algorítmica para a amostragem aleatória pura:

```
i = 1
w_1 ← p(w)
while w_i ≠ EOS:
    i = i + 1
    w_i ← p(w | w_1, ..., w_{i-1})
```

- $i$  e  $w_i$ : Rastreiam o índice posicional e a palavra escolhida.
- $\leftarrow p$ : Indica a extração probabilística da palavra a partir da distribuição.
- **EOS**: O sinal crítico de parada (Fim da Sequência).
- $P(w | \dots)$ : A escolha da próxima palavra depende de todo o contexto histórico.

# A amostragem aleatória não funciona muito bem...

- Embora a amostragem aleatória pura geralmente gere palavras coerentes e de alta probabilidade, existem milhares de palavras estranhas e de baixa probabilidade residindo na cauda da distribuição.
- Cada uma dessas palavras individuais possui uma probabilidade mínima, mas quando somadas matematicamente, elas constituem uma parte grande e perigosa da massa de probabilidade total.
- Portanto, sob amostragem aleatória pura, elas são escolhidas com frequência suficiente para gerar frases completamente estranhas e sem sentido.

# Fatores na amostragem de palavras: Qualidade vs. Diversidade

## Enfatizar palavras com probabilidade média introduz diversidade:

- **Prós:** Resulta em saídas textuais muito mais criativas e diversas.
- **Contras:** Reduz drasticamente a qualidade, resultando em declarações menos factuais e altamente inconsistentes.

## Enfatizar palavras exclusivamente com alta probabilidade prioriza a qualidade:

- **Prós:** Garante que as saídas sejam altamente precisas, logicamente coerentes e factuais.
- **Contras:** Erradica a diversidade, produzindo textos entediantes, altamente repetitivos e robóticos.

# Algoritmo de Amostragem Top-k

Para truncar a perigosa cauda de probabilidade, utilizamos o Top-k:

- 1 Escolha um valor inteiro estático " $k$ " representando o número de palavras.
- 2 Para cada palavra em todo o vocabulário  $V$ , use o modelo de linguagem para calcular a probabilidade dessa palavra dado o prefixo contextual  $p(w_t | w_{<t})$ .
- 3 Ordene as palavras sequencialmente por probabilidade, mantendo apenas as " $k$ " palavras mais prováveis e descartando o resto.
- 4 Renormalize as pontuações das  $k$  palavras restantes para que somem 1, criando uma distribuição de probabilidade válida.
- 5 Selecione aleatoriamente uma palavra das  $k$  palavras restantes, estritamente de acordo com sua probabilidade renormalizada.

# Amostragem Top-p (= amostragem de núcleo)

**Problema Fundamental com o top-k:** O parâmetro  $k$  é fixo, o que significa que pode abranger quantidades muito diferentes da massa de probabilidade total em situações contextuais diferentes (por exemplo, distribuições planas vs. acentuadas).

**A Ideia do Núcleo:** Em vez de uma contagem fixa, mantenha os  $p$  por cento superiores da massa de probabilidade.

Dada uma distribuição  $P(w_t \mid w_{<t})$ , o vocabulário top-p  $V(p)$  é definido matematicamente como o menor conjunto de palavras tal que:

$$\sum_{w \in V(p)} P(w \mid w_{<t}) \geq p$$

(Holtzman et al., 2020)

# Amostragem por temperatura (1/4)

Em vez de truncar o vocabulário, podemos remodelar matematicamente toda a distribuição. Esse conceito extrai intuição da termodinâmica:

- Um sistema físico existente a uma temperatura alta é altamente flexível, energético e pode explorar muitos estados variantes possíveis.
- Um sistema a uma temperatura mais baixa possui energia mais baixa e tem maior probabilidade matemática de explorar apenas um pequeno subconjunto de estados (melhores) estáveis.

Em configurações de amostragem de baixa temperatura ( $\tau \leq 1$ ), forçamos suavemente o algoritmo a:

- Aumentar drasticamente a probabilidade das palavras mais prováveis.
- Diminuir simultaneamente a probabilidade das palavras raras de cauda longa.

## Amostragem por temperatura (2/4)

- **t = 0.1 a 0.3 (Variância Muito Baixa):** Excepcional para executar código de programação, equações matemáticas, traduções estritas ou responder a consultas factuais onde se deseja precisão absoluta e nenhum desvio criativo. O modelo quase sempre escolherá de forma gananciosa a palavra mais lógica.
- **t = 0.7 a 1.0 (Variância Normal/Alta):** Ideal para escrever poesia, sessões de brainstorming ou gerar histórias narrativas, pois a distribuição matemática permite que o modelo arrisque selecionar palavras menos óbvias, gerando uma saída textual muito mais diversa e "criativa".

## Amostragem por temperatura (3/4)

Matematicamente, dividimos o logit bruto  $u$  por um parâmetro de temperatura  $\tau$  antes de passá-lo pela camada final de ativação softmax.

Em vez do cálculo padrão:

$$y = \text{softmax}(u)$$

Calculamos a variante escalonada:

$$y = \text{softmax}\left(\frac{u}{\tau}\right)$$

## Amostragem por temperatura (4/4)

### Por que esse ajuste estrutural funciona?

- Quando  $\tau$  é exatamente 1, a distribuição matemática não muda.
- Quanto menor o  $\tau$ , maiores serão as pontuações diferenciais passadas para o softmax. O softmax empurra inerentemente valores altos para 1 e valores baixos para 0.
- Conforme  $\tau \rightarrow 0$ , a probabilidade da palavra absolutamente mais provável se aproxima assintoticamente de 1.

# Pré-treinamento de Grandes Modelos de Linguagem

# Pré-treinamento de Grandes Modelos de Linguagem

Algoritmos e Arquiteturas

# Paradigma de Pré-treinamento

A ideia monumental que impulsiona as incríveis métricas de desempenho dos modelos de linguagem modernos:

- Primeiro, pré-treinar um modelo Transformer massivo em quantidades astronomicamente grandes de texto bruto usando clusters de computação massivos.
- Em seguida, aplicar esse conhecimento generalizado a novas tarefas altamente específicas.

# Algoritmo de treinamento auto-supervisionado

**Nós fundamentalmente apenas os treinamos para prever a próxima palavra!**

Pegue um corpus massivo de texto. A cada passo de tempo computacional  $t$ ...

- 1 Peça ao modelo neural para prever matematicamente a próxima palavra na sequência.
- 2 Treine o modelo utilizando a retropropagação (backpropagation) do erro e a descida do gradiente para minimizar o erro matemático nesta previsão.

Esse paradigma é classificado como aprendizado "**Auto-supervisionado**" porque não requer anotadores humanos; ele simplesmente utiliza a próxima palavra natural no texto como o rótulo definitivo de verdade de base (ground-truth)!

# Intuição do treinamento do modelo de linguagem: Perda

- **Utilidade da Função de Perda:** A métrica padrão é a perda de entropia cruzada.
- Inerentemente, queremos que o modelo neural atribua uma alta probabilidade à palavra verdadeira e empírica  $w$ .
- Consequentemente, queremos que a perda calculada seja excepcionalmente alta se o modelo atribuir uma probabilidade muito baixa a  $w$ .
- **Definição da Perda CE:** O logaritmo negativo da probabilidade que o modelo atribui exclusivamente à próxima palavra verdadeira  $w$ .
- Se o modelo atribui uma probabilidade muito baixa a  $w$ , o otimizador move forçosamente os bilhões de pesos do modelo na direção multidimensional que garante uma atribuição de probabilidade maior a  $w$  no futuro.

# Perda de entropia cruzada para modelagem de linguagem

A perda CE define a divergência entre a distribuição de probabilidade correta e empírica e a distribuição prevista pelo modelo:

$$L_{CE} = - \sum_{w \in V} y_t[w] \log \hat{y}_t[w]$$

A distribuição verdadeira (ground-truth) correta  $y_t$  sabe a próxima palavra definitivamente, então ela funciona como um vetor one-hot: é exatamente 1 para a próxima palavra real e 0 para todos os outros tokens.


Portanto, nesta soma, todos os termos são multiplicados por zero e desaparecem, exceto um: a probabilidade logarítmica que o modelo atribui à próxima palavra correta. Assim:

$$L_{CE}(\hat{y}_t, y_t) = -\log \hat{y}_t[w_{t+1}]$$

# Técnica de Teacher Forcing

- Em cada posição de token  $t$ , o modelo processa os tokens históricos corretos  $w_{1:t}$ .
- Ele calcula a perda (o logaritmo negativo da probabilidade) para sua previsão do próximo token  $w_{t+1}$ .
- Criticamente, na posição do token subsequente  $t + 1$ , ignoramos estritamente qualquer token errôneo que o modelo possa ter previsto para  $w_{t+1}$ .
- Em vez disso, pegamos a palavra verdadeira correta  $w_{t+1}$  do conjunto de dados, adicionamos de forma segura ao contexto e seguimos em frente. Isso evita o acúmulo de erros durante o treinamento.

**Figura:** Esquema de treinamento de um modelo de linguagem Transformer.



# Os LLMs são treinados principalmente na web

- **Common Crawl:** Instantâneos massivos de toda a web pública produzidos recursivamente pela organização sem fins lucrativos Common Crawl, contendo bilhões de páginas HTML brutas.
- **Colossal Clean Crawled Corpus (C4):** Criado por Raffel et al. (2020), este conjunto de dados contém 156 bilhões de tokens de texto em inglês que foram rigorosamente filtrados por qualidade.
- **O que constitui esses dados?** A maior parte dos tokens de alta qualidade deriva de documentos de patentes, bancos de dados da Wikipedia e sites de notícias internacionais.

# The Pile: um corpus de pré-treinamento projetado

Um conjunto de dados de modelagem de linguagem de código aberto de 825 GiB diversificado e meticulosamente balanceado.

| Acadêmico      | Web & Geral   | Livros & Diálogos   |
|----------------|---------------|---------------------|
| PubMed Central | Pile-CC       | Bibliotik           |
| ArXiv          | OpenWebText2  | PG-19               |
| FreeLaw        | StackExchange | BookCorpus2         |
| PhilPapers     | Wikipedia     | Ubuntu IRC / GitHub |

# O que um modelo aprende no pré-treinamento?

O texto bruto ingerido contém uma enorme quantidade de conhecimento humano. O pré-treinamento com bilhões de textos contendo todo esse conhecimento é o que fundamentalmente dá aos modelos de linguagem sua capacidade de executar tanta lógica.

- Lógica Contextual: "Há caninos por toda parte! Um cachorro na sala da frente e dois cachorros."
- Escalonamento Semântico: "Não era apenas grande, era enorme."
- Recuperação Factual: "A autora de 'Um Teto Todo Seu' é Virginia Woolf."
- Verdades Matemáticas: "A raiz quadrada de 4 é 2."

# Ajuste fino como "pré-treinamento contínuo"

- A abordagem mais direta é treinar ainda mais todos os bilhões de parâmetros do modelo nos novos dados específicos.
- Empregamos exatamente o mesmo método (previsão da próxima palavra) e função de perda matemática (perda de entropia cruzada) utilizados para o pré-treinamento original.
- Tratamos a operação como se os novos dados especializados fossem simplesmente anexados no final da sequência massiva de dados de pré-treinamento.
- Portanto, esse processo é frequentemente classificado na literatura como **pré-treinamento contínuo**.

# Ajuste fino




Figura: Finetuning flow

# Avaliando Grandes Modelos de Linguagem

## Avaliando Grandes Modelos de Linguagem

Métricas e Infraestrutura de Escala.

# Métrica de Perplexidade

A indústria usa a Perplexidade para medir matematicamente quão bem o LM prevê distribuições de texto não vistas.

A perplexidade de um modelo em um conjunto de teste não visto é definida como o inverso da probabilidade que o modelo atribui ao conjunto de teste, normalizada geometricamente pelo comprimento do conjunto de teste.

Para uma sequência de teste de  $n$  tokens  $w_{1:n}$ , a perplexidade é calculada como:

$$\text{Perplexidade}(w_{1:n}) = P(w_{1:n})^{-\frac{1}{n}}$$

# Por que perplexidade em vez de probabilidade bruta?

- A probabilidade bruta depende inteiramente do tamanho do conjunto de teste; a probabilidade se torna assintoticamente menor quanto mais longa for a sequência de texto.
- A perplexidade calcula a probabilidade inversa normalizada pelo número total de palavras (derivada da taxa de entropia cruzada).
- Enquanto a probabilidade opera em uma faixa estreita de  $[0, 1]$ , a faixa de perplexidade abrange  $[1, \infty]$ .
- Quanto maior a probabilidade atribuída à sequência de palavras, menor a perplexidade.

# Leis de Escala

O desempenho empírico do LLM é estritamente dependente de:

- **Tamanho do modelo:** Número absoluto de parâmetros treináveis.
- **Tamanho do conjunto de dados:** A quantidade volumétrica bruta de dados.
- **Computação:** Quantidade absoluta de computação utilizada.

O desempenho de um grande modelo de linguagem (medido pela perda) escala matematicamente como uma lei de potência:

$$L(N) = (N_c/N)^{\alpha_N} \quad L(D) = (D_c/D)^{\alpha_D} \quad L(C) = (C_c/C)^{\alpha_C}$$

# Número de parâmetros não-embedding N

Podemos estimar matematicamente o total de parâmetros via:

$$N \approx 2d_{model}n_{layers}(2d_{attn} + d_{ff})$$

$$\approx 12n_{layers}d_{model}^2$$

Assumindo proporções dimensionais padrão de  $d_{attn} = d_{ff}/4 = d_{model}$ .

Assim, calculando para a arquitetura do GPT-3, possuindo  $n = 96$  camadas e uma dimensionalidade massiva de  $d = 12288$ , determinamos:

$$12 \times 96 \times 12288^2 \approx 175 \text{ bilhões de parâmetros.}$$

# O Gargalo do Cache KV

Durante a fase de pré-treinamento, calculamos a atenção matemática com eficiência em lotes paralelos massivos. Porém, isso falha na inferência, pois geramos tokens sequencialmente.

- Para cada novo token  $x$ , multiplicamos pelas matrizes de peso  $W_Q, W_K, W_V$ .
- O cálculo exige vetores chave e valor para todos os tokens anteriores  $x_{<i}$ , gerando um custo computacional  $O(N^2)$ .
- **A Solução de Engenharia:** Armazene os vetores na memória VRAM da GPU no cache KV, para uso com velocidade de inferência  $O(N)$ .

# Arquitetura do Cache KV




Figura: Representação do cache KV.

# Teoria LORA (Adaptação de Baixo Posto)

Considere uma matriz de pesos base  $W$  ( $N \times d$ ) que teoricamente precisa ser atualizada durante o ajuste fino. No algoritmo LORA, congelamos  $W$  e atualizamos uma decomposição de baixo posto de  $W$ :

- Matriz  $A$  com formato  $N \times r$
- Matriz  $B$  com formato  $r \times d$
- Onde  $r$  (posto) é muito pequeno (ex: 1, 2 ou 8)

Substituímos computacionalmente  $W + \Delta W$  por  $W + BA$ .

Passagem direta (Forward pass):

$$h = xW + xAB$$

# Danos Sociais dos Grandes Modelos de Linguagem

- **Alucinação**
- **Litígio de Direitos Autorais**
- **Violações de Privacidade**
- **Toxicidade e Exploração**
- **Desinformação Política**

# Alucinação

Chatbots rotineiramente 'alucinam' políticas corporativas falsas ou fatos inexistentes.

*Chatbots May 'Hallucinate'  
More Often Than Many Realize*

*What Can You Do When A.I. Lies  
About You?*

People have little protection or recourse when the technology creates and spreads falsehoods about them.

**Air Canada loses court case after its chatbot hallucinated  
fake policies to a customer**

The airline argued that the chatbot itself was liable. The court disagreed.

# Litígio de Direitos Autorais

Ações judiciais por infração massiva no uso de obras protegidas durante o treinamento sem permissão.

Generative AI claims to produce new language and images, but when those ideas are based on copyrighted material, who gets the credit? A new paper from Stanford University looks for answers.

Jan 9, 2023 | Andrew M. ...



Authors Sue OpenAI Claiming Mass Copyright  
Infringement of Hundreds of Thousands of Novels

***The Times Sues OpenAI and Microsoft  
Over A.I. Use of Copyrighted Work***

Millions of articles from The New York Times were used to train chatbots that now compete with it, the lawsuit said.



# Violações de Privacidade

Vazamento acidental de e-mails e números de telefone privados extraídos dos dados de treinamento.

**How Strangers Got My Email  
Address From ChatGPT's Model**

# Toxicidade e Exploração

O processo de limpeza dos dados muitas vezes exige que humanos avaliem conteúdos tóxicos.

**The New AI-Powered Bing Is Threatening Users.**

## **Cleaning Up ChatGPT Takes Heavy Toll on Human Workers**

Contractors in Kenya say they were traumatized by effort to screen out descriptions of violence and sexual abuse during run-up to OpenAI's hit chatbot

# Desinformação Política

Geração de falsidades altamente persuasivas que podem afetar cenários globais e eleições.

**Chatbots are generating false and misleading information about U.S. elections**

## Referências Bibliográficas I



Anthropic. 2025. Release notes: System prompts.  
<https://docs.anthropic.com/en/release-notes/system-prompts>.



Bellegarda, J. R. 1997. A latent semantic analysis framework for large-span language modeling. EUROSPEECH.



Bengio, Y., R. Ducharme, and P. Vincent. 2000. A neural probabilistic language model. NeurIPS.



Bengio, Y., R. Ducharme, P. Vincent, and C. Jauvin. 2003. A neural probabilistic language model. *JMLR*, 3:1137–1155.



Bengio, Y., H. Schwenk, J.-S. Senécal, F. Morin, and J.-L. Gauvain. 2006. Neural probabilistic language models. In *Innovations in Machine Learning*, 137–186. Springer.



Bickmore, T. W., et al. 2018. Patient and consumer safety risks when using conversational assistants for medical information. *Journal of Medical Internet Research*, 20(9):e11510.



Blodgett, S. L., S. Barocas, H. Daumé III, and H. Wallach. 2020. Language (technology) is power: A critical survey of “bias” in NLP. *ACL*.



Bommasani, R., et al. 2021. On the opportunities and risks of foundation models. ArXiv.



Brown, T., et al. 2020. Language models are few-shot learners. NeurIPS, 33.



Carlini, N., et al. 2021. Extracting training data from large language models. USENIX Security 21.



# Referências Bibliográficas III

-  Dodge, J., et al. 2021. Documenting large webtext corpora: A case study on the colossal clean crawled corpus. EMNLP.
-  Ethayarajh, K. and D. Jurafsky. 2020. Utility is in the eye of the user: A critique of NLP leaderboards. EMNLP.
-  Friedman, B., D. G. Hendry, and A. Borning. 2017. A survey of value sensitive design methods. Foundations and Trends in Human-Computer Interaction.
-  Friedman, B. and D. G. Hendry. 2019. Value Sensitive Design: Shaping Technology with Moral Imagination. MIT Press.
-  Gao, L., et al. 2020. The Pile: An 800GB dataset of diverse text for language modeling. ArXiv.
-  Gehman, S., S. Gururangan, M. Sap, Y. Choi, and N. A. Smith. 2020. RealToxicityPrompts: Evaluating neural toxic degeneration in language models. Findings of EMNLP.
-  Gururangan, S., et al. 2020. Don't stop pretraining: Adapt language models to domains and tasks. ACL.
-  Hashimoto, T., M. Srivastava, H. Namkoong, and P. Liang. 2018. Fairness without demographics in repeated loss minimization. ICML.
-  Heafield, K. 2011. KenLM: Faster and smaller language model queries. Workshop on Statistical Machine Translation.

# Referências Bibliográficas IV

-  Henderson, P., et al. 2017. Ethical challenges in data-driven dialogue systems. AAAI/ACM AI Ethics and Society Conference.
-  Henderson, P., et al. 2020. Towards the systematic reporting of the energy and carbon footprints of machine learning. JMLR.
-  Henderson, P., et al. 2023. Foundation models and fair use. JMLR, 24(400):1–79.
-  Hofmann, V., P. R. Kalluri, D. Jurafsky, and S. King. 2024. Ai generates covertly racist decisions about people based on their dialect. Nature, 633(8028):147–154.
-  Ischen, C., et al. 2019. Privacy concerns in chatbot interactions. International Workshop on Chatbot Research and Design.
-  Jelinek, F., R. L. Mercer, and L. R. Bahl. 1975. Design of a linguistic statistical decoder for the recognition of continuous speech. IEEE Transactions on Information Theory.
-  Khattab, O., et al. 2024. DSPy: Compiling declarative language model calls into self-improving pipelines. ICLR.
-  Kiela, D., et al. 2021. Dynabench: Rethinking benchmarking in NLP. NAACL HLT.
-  Landauer, T. K., D. Laham, B. Rehder, and M. E. Schreiner. 1997. How well can passage meaning be derived without using word order? COGSCI.

# Referências Bibliográficas V

-  Liang, P., et al. 2023. Holistic evaluation of language models. Transactions on Machine Learning Research.
-  Liu, H., et al. 2020. Does gender matter? Towards fairness in dialogue systems. COLING.
-  Llama Team. 2024. The llama 3 herd of models.
-  Longpre, S., et al. 2024a. Consent in crisis: The rapid decline of the ai data commons. ArXiv preprint.
-  Longpre, S., et al. 2024b. A pretrainer's guide to training data: Measuring the effects of data age, domain coverage, quality, & toxicity. NAACL HLT.
-  McGuffie, K. and A. Newhouse. 2020. The radicalization risks of GPT-3 and advanced neural language models. ArXiv.
-  Mikolov, T., et al. 2010. Recurrent neural network based language model. INTERSPEECH.
-  Mikolov, T., et al. 2011. Extensions of recurrent neural network language model. ICASSP.
-  Mikolov, T., K. Chen, G. S. Corrado, and J. Dean. 2013a. Efficient estimation of word representations in vector space. ICLR.
-  Mikolov, T., I. Sutskever, K. Chen, G. S. Corrado, and J. Dean. 2013b. Distributed representations of words and phrases and their compositionality. NeurIPS.

# Referências Bibliográficas VI

-  Miller, G. A. and J. A. Selfridge. 1950. Verbal context and the recall of meaningful material. *American Journal of Psychology*, 63:176–185.
-  Min, S., et al. 2022. Rethinking the role of demonstrations: What makes in-context learning work? EMNLP.
-  Nadeem, M., A. Bethke, and S. Reddy. 2021. StereoSet: Measuring stereotypical bias in pretrained language models. *ACL*.
-  Neff, G. and P. Nagy. 2016. Talking to bots: Symbiotic agency and the case of Tay. *International Journal of Communication*.
-  Parrish, A., et al. 2022. BBQ: A hand-built bias benchmark for question answering. *Findings of ACL 2022*.
-  Peters, M., et al. 2018. Deep contextualized word representations. *NAACL HLT*.
-  Radford, A., et al. 2019. Language models are unsupervised multitask learners. *OpenAI tech report*.
-  Raffel, C., et al. 2020. Exploring the limits of transfer learning with a unified text-to-text transformer. *JMLR*, 21(140):1–67.
-  Rawls, J. 2001. *Justice as fairness: A restatement*. Harvard University Press.
-  Reeves, B. and C. Nass. 1996. *The Media Equation: How People Treat Computers, Television, and New Media Like Real People and Places*. Cambridge University Press.

# Referências Bibliográficas VII

-  Rosenfeld, R. 1992. Adaptive Statistical Language Modeling: A Maximum Entropy Approach. Ph.D. thesis, Carnegie Mellon University.
-  Rosenfeld, R. 1996. A maximum entropy approach to adaptive statistical language modeling. *Computer Speech and Language*, 10:187–228.
-  Sagawa, S., P. W. Koh, T. B. Hashimoto, and P. Liang. 2020. Distributionally robust neural networks for group shifts: On the importance of regularization for worst-case generalization. *ICLR*.
-  Shannon, C. E. 1948. A mathematical theory of communication. *Bell System Technical Journal*, 27(3):379–423.
-  Sheng, E., K.-W. Chang, P. Natarajan, and N. Peng. 2019. The woman worked as a babysitter: On biases in language generation. *EMNLP*.
-  Soldaini, L., et al. 2024. Dolma: An open corpus of three trillion tokens for language model pretraining research. *ArXiv*.
-  Stolcke, A. 2002. SRILM – an extensible language modeling toolkit. *ICSLP*.
-  Strubell, E., A. Ganesh, and A. McCallum. 2019. Energy and policy considerations for deep learning in NLP. *ACL*.
-  Vaswani, A., et al. 2017. Attention is all you need. *NeurIPS*.

## Referências Bibliográficas VIII



- Zhang, A. K., et al. 2025. Language model developers should report train-test overlap. ICML.

# OBRIGADO